



UNIVERSITÀ DEGLI STUDI DI CATANIA
DIPARTIMENTO DI MATEMATICA E INFORMATICA
CORSO DI LAUREA MAGISTRALE IN INFORMATICA

Nome Autore

Titolo della Tesi

RELAZIONE PROGETTO FINALE

Professore: Dario Allegra

Anno Accademico 2025 - 2026

Abstract

L'abstract va inserito qui. [1]

Indice

1	Introduzione	3
2	Methodology	4
3	Methodology	5
4	Experiments	6
5	Results	7
6	Conclusion	8
	Bibliografia	9

Capitolo 1

Introduzione

Qui definisci il perimetro. Non dilungarti troppo, vai dritto al punto.

Il Problema: Le immagini ottiche satellitari (es. Sentinel-2) sono fondamentali per il monitoraggio terrestre, ma circa la metà delle osservazioni è coperta da nuvole o foschia. Questo crea buchi nei dati temporali.

Perché è importante: Serve ricostruire le informazioni mancanti per applicazioni come l'agricoltura, il monitoraggio dei disastri e la classificazione del suolo.

Le Sfide (Challenges):

Le nuvole possono essere spesse (nessuna info ottica sottostante) o sottili/trasparenti.

Le ombre delle nuvole creano artefatti scuri.

La variabilità temporale (il paesaggio cambia nel tempo, rendendo difficile usare immagini vecchie per riempire i buchi).

Obiettivo del Progetto: Eseguire un benchmark su Google Colab confrontando tre approcci di complessità crescente (Baseline Statistica, Metodo Fisico Single-Image, Deep Learning Multimodale SOTA) utilizzando il dataset SEN12MS-CR-TS.

vedere un po' la struttura qua: <https://ieeexplore.ieee.org/document/11039671?denied=citarlo> nel caso

Capitolo 2

Methodology

Qui descrivi la teoria degli algoritmi scelti (senza codice). Usa la classificazione della review (PDF 2).

Classificazione Generale: Spiega che esistono metodi Single-Image (usano solo l'immagine corrente), Multitemporali (usano la storia del pixel) e Multimodali (usano sensori diversi come il SAR).

Metodo 1: Baseline Multitemporale (Mosaicing/Least Cloudy):

Spiega il concetto di prendere il pixel "migliore" o la mediana lungo l'asse temporale. È semplice ma fallisce se l'area cambia molto nel tempo.

Metodo 2: Single-Image Physical Model (Dark Channel Prior - DCP):

Spiega che si basa sull'assunto che in assenza di nuvole, in ogni patch c'è almeno un pixel scuro. Le nuvole violano questa regola. È un metodo fisico che non richiede training.

Metodo 3: Deep Learning Multimodal SOTA (UnCRtainTS):

Descrivi brevemente il modello scelto (UnCRtainTS o ResNet 3D proposto nel paper del dataset).

Punti chiave: Sfrutta la fusione tra dati Ottici e SAR (Sentinel-1). Il SAR penetra le nuvole, fornendo una guida strutturale anche con copertura nuvolosa totale.

Capitolo 3

Methodology

Descrizione tecnica dei dati usati.

SEN12MS-CR-TS: Spiega che è un dataset curato specificamente per il cloud removal multitemporale.

Caratteristiche:

Contiene serie temporali di 30 osservazioni per ROI (Region of Interest).

Include dati appaiati Sentinel-1 (SAR) e Sentinel-2 (Ottico).

Copertura globale e stagionale.

Preprocessing: Menziona che le immagini sono patch 256×256 , con risoluzione 10m.

Capitolo 4

Experiments

Qui descrivi l'implementazione pratica (il tuo lavoro su Colab).

Ambiente Sperimentale:

Utilizzo di Google Colab (risorse limitate: GPU T4, RAM 12GB).

Necessità di ottimizzare il caricamento dati. (es. "L'analisi è limitata a una sola zona geografica per vincoli computazionali").

Setup dei Dati (La strategia "Single ROI"):

Spiega che, dato il volume del dataset (2TB), hai scaricato e processato solo una specifica ROI (es. ROI 118) del test set per dimostrare la fattibilità del benchmark.

Dettagli Implementativi:

Baseline: Implementata via NumPy calcolando la mediana temporale.

DCP: Utilizzo di librerie Python standard per il dehazing.

UnCRtainTS: Caricamento del modello pre-addestrato (Inference only) per ovviare ai tempi di training proibitivi su Colab.

Protocollo di Valutazione: Confronto tra l'immagine ricostruita e l'immagine "Ground Truth" (senza nuvole) fornita nel dataset.

Capitolo 5

Results

Il cuore scientifico del report.

Metriche di Valutazione: Definisci brevemente le formule usate (prese dal paper dataset):

PSNR: Rapporto segnale-rumore (più alto è meglio).

SSIM: Similarità strutturale percepita dall'occhio umano (più alto è meglio, max 1.0).

RMSE: Errore quadratico medio (più basso è meglio).

Tabella Quantitativa:

Una tabella semplice con le colonne: Metodo — PSNR — SSIM — RMSE.

Confronta i valori medi ottenuti sulla tua ROI. (Esempio atteso: UnCRtainTS $\hat{}$ Mosaicing $\hat{}$ DCP).

Analisi Qualitativa (Visual Results):

Inserisci una figura composta (Input Nuvoloso — Output Baseline — Output DCP — Output Deep Learning — Ground Truth).

Commenta l'immagine: "Come si vede in Fig. X, il metodo DCP scurisce troppo l'immagine, la Baseline perde dettagli temporali, mentre il Deep Learning recupera la texture grazie al SAR".

Capitolo 6

Conclusion

Sintesi finale.

Riepilogo: Conferma che i metodi multimodali (SAR+Ottico) e basati su Deep Learning superano nettamente i metodi statistici classici.

Trade-off: Sottolinea però il "costo": UnCRtainTS richiede GPU e dati SAR complessi, mentre il Mosaicing è istantaneo e gira su CPU.

Sviluppi Futuri: Estendere il benchmark a più ROI se si avessero più risorse o testare i nuovi modelli a "Diffusione" citati nella letteratura recente.

Bibliografia

[1] Iplab, 2015. <http://iplab.dmi.unict.it/>.